Base64 - Fundamentos

Segurança Computacional

Prof. Paulo Henrique Lopes Silva

Roteiro

- Definição.
- Utilidade.
- Exemplos.

O que é Base64?

- Converter dados binários em strings ASCII.
- Dados binários são convertidos em caracteres de 6 bits.

O problema

- Protocolos tradicionais de e-mail (como o SMTP original) foram projetados na década de 1980 para transportar apenas texto simples codificado em ASCII de 7 bits.
  - Risco de corrupção: Arquivos binários (imagens, vídeos, PDFs) usam 8 bits (0 a 255).
  - Interpretação incorreta: Se enviados em texto puro, os bytes acima de 127 ou na faixa de comandos (0–31, como quebra de linha ou fim de arquivo) são lidos por servidores como comandos do sistema.
  - Consequência: Os servidores tentam reformatar ou alterar esses bytes "especiais", corrompendo o arquivo permanentemente.

A solução

- O Base64 é uma codificação (RFC 2045) que converte qualquer arquivo binário em uma sequência composta apenas por caracteres ASCII seguros e imprimíveis.
  - Garante a integridade do arquivo: Evita que imagens, PDFs e vídeos sejam corrompidos ou alterados por servidores ao trafegarem por sistemas antigos projetados apenas para texto.
  - Compatibilidade universal: Permite enviar anexos e mídias em protocolos baseados em texto (como e-mail/SMTP e HTML/CSS) sem que o sistema interprete bytes binários como comandos de controle.

Qual a utilidade?

- Transferência de dados em JSON/XML:
  - Para transmitir imagens ou arquivos binários dentro de formatos que só aceitam texto.
- Autenticação HTTP *(Auth)*:
  - Usuário e senha são codificados em Base64 antes de serem enviados no cabeçalho HTTP.
- URLs e APIs Web:
  - Usada para embutir dados diretamente em uma URL ou corpo de requisição.
- Certificados digitais e criptografia:
  - Chaves públicas/privadas muitas vezes são representadas em Base64 para facilitar armazenamento e envio.

Funcionamento

- Base64 divide os caracteres em segmentos de 6 bits em 3 bytes.
  - E os representa em caracteres ASCII.
- Funciona em etapas:
  - Converter o texto em sua representação binária.
  - Dividir a string binária em blocos de 6 bits (2^6 = 64 caracteres).
    - Garante que os dados codificados possam ser impressos e legíveis por humanos (nenhum caractere especial é usado).
    - Dez dígitos, 26 letras maiúsculas, 26 letras minúsculas, além do ‘+’ e da ‘/’.
    - O 65º caractere é o ‘=’, chamado de *pad* (usado para preencher o último segmento caso não tenha 6 bits).
  - Converter cada bloco em um decimal entre 0 e 63.
  - Mapear o decimal para o caractere correspondente na tabela de codificação Base64.

Funcionamento: exemplo

- Considere os caracteres 155, 162 e 233.
  - Eles geram essa *stream* de bits: 100110111010001011101001.
  - Dividir em 6 bits: 100110 111010 001011 101001.
  - Converter cada bloco em um decimal entre 0 e 63: 38, 58, 11 e 41.
  - Converter em caracteres ASCII (usando a tabela da codificação Base64):
    - 38 - m.
    - 58 - 6.
    - 11 - L.
    - 41 - p.

Table 1: The Base 64 Alphabet

Value	Encoding	Value	Encoding	Value	Encoding	Value	Encoding
0	A	17	R	34	i	51	z
1	B	18	S	35	j	52	0
2	C	19	T	36	k	53	1
3	D	20	U	37	l	54	2
4	E	21	V	38	m	55	3
5	F	22	W	39	n	56	4
6	G	23	X	40	o	57	5
7	H	24	Y	41	p	58	6
8	I	25	Z	42	q	59	7
9	J	26	a	43	r	60	8
10	K	27	b	44	s	61	9
11	L	28	c	45	t	62	+
12	M	29	d	46	u	63	/
13	N	30	e	47	v		
14	O	31	f	48	w	(pad)	=
15	P	32	g	49	x		
16	Q	33	h	50	y		

Funcionamento: exemplo 2

- Considere a mensagem “abc”.
  - Ela gera essa *stream* de bits: 01100001 01100010 01100011.
  - Dividir em 6 bits: 011000 010110 001001 100011.
  - Converter cada bloco em um decimal entre 0 e 63:
    - 011000 = 24
    - 010110 = 22
    - 001001 = 9
    - 100011 = 35
  - Converter em caracteres ASCII (usando a tabela da codificação Base64):
    - 24 - 'Y'
    - 22 - 'W'
    - 9 - 'J'
    - 35 - 'j'

Table 1: The Base 64 Alphabet

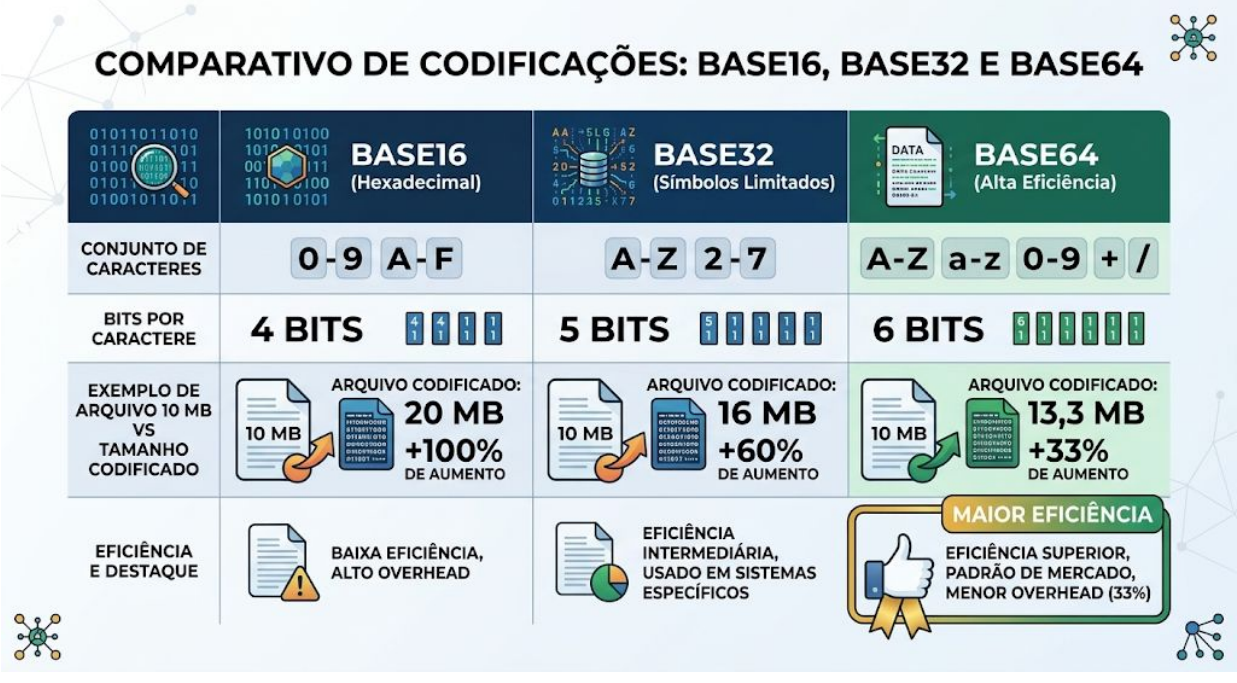
Value	Encoding	Value	Encoding	Value	Encoding	Value	Encoding
0	A	17	R	34	i	51	z
1	B	18	S	35	j	52	0
2	C	19	T	36	k	53	1
3	D	20	U	37	l	54	2
4	E	21	V	38	m	55	3
5	F	22	W	39	n	56	4
6	G	23	X	40	o	57	5
7	H	24	Y	41	p	58	6
8	I	25	Z	42	q	59	7
9	J	26	a	43	r	60	8
10	K	27	b	44	s	61	9
11	L	28	c	45	t	62	+
12	M	29	d	46	u	63	/
13	N	30	e	47	v		
14	O	31	f	48	w	(pad)	=
15	P	32	g	49	x		
16	Q	33	h	50	y		

Funcionamento

- Problema:
  - Se o tamanho dos dados originais, em bytes, **não** for for múltiplo de três.
    - Múltiplo de 24 em bits.
  - São necessários três bytes para uma codificação adequada.
- Solução:
  - Para cada 3 bytes de entrada, tem-se 4 caracteres Base64 na saída.
  - Se os dados não completarem múltiplos de 3 bytes, usa-se *padding* =:
    - 1 byte extra: adicionar ==
    - 2 bytes extras: adicionar =

Existem outras bases

- O Base64 foi escolhido por oferecer a melhor taxa de compressão de texto entre as opções sem violar as limitações dos sistemas de transmissão.



Referências

- JOSEFSSON, Simon. The Base16, Base32, and Base64 Data Encodings. Fremont: Internet Engineering Task Force (IETF), 2006. (RFC 4648). Disponível em: https://www.rfc-editor.org/rfc/rfc4648.
- ORACLE. Class Base64. Documentation – Java Platform, Standard Edition 8. 2014. Disponível em: https://docs.oracle.com/javase/8/docs/api/java/util/Base64.html.
- MOZILLA FOUNDATION. Base64. MDN Web Docs. 2023. Disponível em: https://developer.mozilla.org/pt-BR/docs/Glossary/Base64.